

Predviđanje srčane bolesti

Nemanja Manić, BI 34/2021

I. UVOD

Srčana bolest predstavlja opšti pojam koji obuhvata različite poremećaje u radu srca i pripada grupi kardiovaskularnih bolesti (KVB) [1]. KVB su vodeći uzrok smrtnosti u svetu, pri čemu četiri od pet smrtnih slučajeva povezanih sa njima nastaju usled srčanog ili moždanog udara [2]. Pravovremena identifikacija osoba sa povećanim rizikom od razvoja srčane bolesti ima ključnu ulogu u prevenciji komplikacija i smanjenju smrtnosti. Kreiranje modela klasifikacije omogućava predviđanje prisustva srčane bolesti na osnovu medicinskih karakteristika pacijenata, čime se doprinosi ranijoj dijagnostici i efikasnijem lečenju.

II. BAZA PODATAKA

A. Struktura baze podataka

Korišćena baza podataka je nastala integracijom nekoliko ranije dostupnih skupova podataka koji do sada nisu bili objedinjeni. U njoj je kombinovano pet različitih baza o srčanim bolestima, pri čemu je izdvojeno 11 zajedničkih obeležja [3]. Baza sadrži informacije o medicinskim karakteristikama pacijenata, kao i oznaku da li pacijent boluje od srčane bolesti ili ne. Pre obrade, baza obuhvata 918 uzoraka i 11 obeležja od kojih je 5 numeričkog, a 6 kategoričkog tipa. Numerička obeležja su Starost, Krvni pritisak, Holesterol, Maksimalan broj otkucaja srca i Depresija ST segmenta izazvana fizičkim naporom. U kategorička obeležja spadaju Pol, Tip bola u grudima, Nivo šećera u krvi, EKG u mirovanju, Angina izazvana fizičkim naporom i Nagib ST segmenta tokom fizičkog napora.

B. Obrada podataka

Analizom baze podataka utvrđeno je da nema nedostajućih vrednosti. Međutim, prisutne su vrednosti koje nemaju fiziološkog smisla i koje bi implicirale da pacijent nije živ.


Minimalne vrednosti obeležja Holesterol i Krvni pritisak iznose 0, što nije fiziološki moguće (Sl. 1.). Pre svega, obeležje Krvni pritisak sadrži jedan uzorak sa vrednošću 0. Pošto taj uzorak predstavlja samo 0,1 % u odnosu na ukupan broj uzoraka, a vrednost obeležja Holesterol je takođe 0 u okviru istog uzorka, odlučeno je da se ovaj uzorak ukloni iz baze. Najveći problem predstavljaju vrednosti 0 kod obeležja Holesterol, s obzirom da se

pojavljuju kod 171 uzorka. Za dopunu ovih vrednosti razmatrane su dve metode: *mean* i *median* dopuna. Odbacivanje svih 171 uzorka nije razmatrano, jer bi to značilo odbacivanje nešto ispod 20% uzoraka.


	Cholesterol	RestingBP
count	918.000000	918.000000
mean	198.799564	132.396514
std	109.384145	18.514154
min	0.000000	0.000000
25%	173.250000	120.000000
50%	223.000000	130.000000
75%	267.000000	140.000000
max	603.000000	200.000000

Sl. 1. Prikaz statističkih parametara obeležja Holesterol i Krvni pritisak.

Na Sl. 2. i Sl. 3. prikazani su histogrami obeležja Holesterol nakon *mean* i *median* dopune. Uočava se da razlika između ove dve metode nije značajna. Odlučeno je da se koristi *mean* dopuna, jer daje blago manji koeficijent asimetrije.



Sl. 2. Histogram obeležja Holesterol nakon *mean* dopune.




Sl. 3. Histogram obeležja Holesterol nakon *median* dopune.

C. Analiza obeležja


U nastavku će biti sprovedena analiza pojedinih obeležja kako bi se uočile razlike između pacijenata sa i bez srčane bolesti.

Analiza pokazuje da su muškarci češće dijagnostikovani sa srčanom bolešću u poređenju sa ženama (Sl. 4.).




Sl. 4. Distribucija pacijenata sa i bez srčane bolesti u zavisnosti od pola pacijenata.

Srčana bolest se često dijagnostikuje kada je prisutna angina izazvana fizičkim naporom (Sl. 5.).



Sl. 5. Distribucija pacijenata sa i bez srčane bolesti u zavisnosti od prisustva angine izazvane fizičkim naporom.


Prisustvo srčane bolesti je zabeleženo i kod pacijenata bez izraženih simptoma (ASY), što dodatno potvrđuje važnost ranog otkrivanja (Sl. 6.).



Sl. 6. Distribucija pacijenata sa i bez srčane bolesti u zavisnosti od tipa bola u grudima.

III. KLASIFIKATORI

Naš zadatak predstavlja klasifikaciju uzoraka u dve klase. Sl. 7. prikazuje broj uzoraka koji pripadaju svakoj klasi, iz čega se može videti da su klase gotovo balansirane. Ova informacija bila je značajna za izbor odgovarajućih klasifikatora i procenu njihove primene. Za potrebe klasifikacije, skup podataka je podeljen na trening skup (90%) i test skup (10%), pri čemu je trening skup korišćen za obučavanje modela, dok je test skup izdvojen isključivo za evaluaciju performansi.



Sl. 7. Raspodela uzoraka po klasama.

U cilju rešavanja problema klasifikacije, koristili smo sledeće klasifikatore: logističku regresiju (engl. *Logistic Regression*), klasifikator metodom k najbližih suseda (engl. *k-Nearest Neighbors*), stablo odluke (engl. *Decision Tree*) i mašina na bazi vektora nosača (engl. *Support Vector Classifier*).

A. Logistička regresija

Logistička regresija (LOG) definiše statistički model koji se koristi za predviđanje aposteriorne verovatnoće klase za dati uzorak. To je generalizovani linearni regresioni model koji za dati uzorak na ulazu predviđa verovatnoću da uzorak pripada klasi 1, koristeći odgovarajuću nelinearnu funkciju ulaznih promenljivih [4].

B. Klasifikator metodom k najbližih suseda

Metoda k najbližih suseda (kNN) spada u grupu metoda kasnog učenja, što podrazumeva odlaganje obrade uzoraka za obuku do trenutka kada je potrebno klasifikovati neobeleženi uzorak. Algoritam je intuitivan i neparametarski, a klasifikacija novih uzoraka zasniva se na

sličnosti sa uzorcima iz skupa za obuku. To podrazumeva pronalaženje k najbližih suseda iz trening skupa, pri čemu se vrednost k unapred definiše. Nepoznati uzorak se zatim svrstava u klasu koja je najzastupljenija među tim susedima [4] [5].

C. Stablo odluke

Stablo odluke (DT) predstavlja jednu od često korišćenih metoda nadgledanog učenja. Algoritam pronalazi optimalno pitanje na osnovu kojeg vrši particiju čvora prolaskom kroz skup mogućih pitanja i procenom u kojoj meri će čvorovi formirani na osnovu svakog od tih pitanja biti „čisti“. Čistoća određenog skupa, odnosno čvora, podrazumeva što izraženiju dominaciju jedne od klasa u njemu [4].

D. Mašina na bazi vektora nosača

Klasifikator pod nazivom „mašina na bazi vektora nosača“ (SVC) prvenstveno se koristi za rešavanje problema binarne klasifikacije tako što identifikuje hiperpovrš koja treba da razdvoji uzorke u prostoru obeležja tako da između oblasti popunjenih uzorcima različitih klasa postoji što širi prostor. Mašina na bazi vektora nosača zasniva se na klasifikatoru maksimalne margine, čiji je cilj da odredi hiperravan koja će na optimalan način podeliti prostor na dva dela tako da se u jednom delu nađu uzorci iz jedne klase, a u drugom delu uzorci iz druge [4].

E. Izbor metrike i određivanje hiperparametara

U cilju pronalaženja optimalnih hiperparametara za svaki klasifikator korišćen je postupak unakrsne validacije pomoću funkcije *GridSearchCV*. Ova funkcija pretražuje unapred definisan skup vrednosti hiperparametara i bira kombinaciju koja daje najbolje rezultate prema izabranoj meri uspešnosti.

Kod logističke regresije skup vrednosti hiperparametara koji su bili zadati unapred, a na osnovu kojih je funkcija *GridSearchCV* birala najbolje su sledeći: *C* (0.01, 0.1, 1, 10, 100), *penalty* (l1, l2), *solver* (liblinear), *class_weight* (None, balanced) i *max_iter* (1000, 5000). *C* predstavlja regularizacioni parametar: što je njegova vrednost manja, to označava jaču regularizaciju i manju kompleksnost modela, dok veće vrednosti smanjuju regularizaciju. Parametar *penalty* određuje koji tip regularizacije će se koristiti. *Solver* je algoritam koji se koristi za optimizaciju tokom obuke logističke regresije. *Class_weight* služi za postavljanje težinskih faktora za uzorke različitih klasa. Parametar *max_iter* postavlja maksimalan broj iteracija koje algoritam može da izvrši tokom procesa optimizacije [4].

Za kNN klasifikator, unapred zadati skup vrednosti hiperparametara je sledeći: *n_neighbors* (1, 2, 3, 4, 5) i *metric* (euclidean, manhattan). Parametar *n_neighbors* označava broj suseda koji se razmatraju, tj. vrednost k, dok parametar *metric* određuje funkciju rastojanja koja se koristi za određivanje sličnosti između uzoraka [4].

Za stablo odluke to su sledeće vrednosti: *criterion* (gini, entropy), *max_depth* (5, 10, 15), *min_samples_split* (0.01, 0.05) i *class_weight* (None, balanced). *Criterion* određuje

kako se meri „čistoća“ podataka u svakom čvoru stabla prilikom odlučivanja o podeli podataka. *Max_depth* parametar ukoliko nije podešen, stablo se deli dok listovi ne postanu potpuno čisti ili dok ne sadrže *min_samples_split* uzoraka. *Min_samples_split* određuje minimalan broj uzoraka koji je potreban da bi se podelio čvor [4].


Na kraju za SVC: *C* (0.1, 1, 10, 100), kernel (*linear*, *poly*, *rbf*, *sigmoid*) i *gamma* (*scale*, *auto*). Kernel su funkcije koje pomažu u transformaciji podataka iz nižih dimenzija u više. *Gamma* je parametar rbf kernela. Kao kriterijum korišćena je osetljivost (engl. *sensitivity*, *recall*), budući da je u problemu detekcije srčane bolesti prioritet pravilno identifikovati što veći broj obolelih pacijenata. Ista procedura primenjena je i u prostoru redukovane dimenzionalnosti [4].

IV. SMANJENJE DIMENZIONALNOSTI

U cilju smanjenja kompleksnosti modela i bolje interpretabilnosti podataka, primenjene su dve metode za redukciju dimenzionalnosti: PCA (*Principal Component Analysis*) i LDA (*Linear Discriminant Analysis*).

Cilj PCA je da predstavi uzorke iz visokodimenzionalnog prostora u prostoru sa manjim brojem dimenzija što verodostojnije, odnosno, zadržavajući u što većoj meri varijansu sadržanu u podacima [4]. U našem slučaju korišćen je parametar *n_components*=0.9, što znači da će sačuvati 90% ukupne varijanse podataka. Kao rezultat toga, broj dimenzija u trening skupu podataka je smanjen sa 15 obeležja na 11 glavnih, što je omogućilo optimizaciju procesa obuke modela. Sa druge strane, cilj LDA jeste da se dimenzionalnost prostora smanji, a da se pritom očuva što više diskriminativnih informacija [4]. Ovde smo koristili parametar *n_components*=1, što znači da je odabrana samo jedna komponenta koja najbolje razlikuje klase. Nakon primene LDA, broj dimenzija u trening skupu je smanjen sa 15 obeležja na 1 komponentu, koja obuhvata ključne informacije potrebne za klasifikaciju.

Jasno je razdvajanje između klasa, što ukazuje da je LDA uspešno pronašla komponentu koja dobro diferencira pacijente sa srčanom bolešću od zdravih (Sl. 7.).



Sl. 7. Histogram uzoraka nakon primene LDA.

V. POREĐENJE KLASIFIKATORA

U razmatranje za optimalni model uzeli smo sledeće klasifikatore LOG, SVC(PCA) i SVC(LDA). Model SVC(LDA) ostvario je najveću osetljivost (92%) što je u

skladu sa ciljem da se maksimizira odziv, ali uz značajno nižu preciznost (78%), što ukazuje na veći broj lažno pozitivnih predikcija. Model SVC(PCA) ostvario je nešto manju osetljivost (88%), uz višu preciznost (83%). Ipak, kako razlika u osetljivosti između modela LOG (82%) i SVC(PCA) (88%) nije značajno velika, a preciznost je znatno viša kod modela LOG (93%), odabran je upravo LOG kao optimalni model, jer postiže najbolji balans između osetljivosti i preciznosti (Tabela 1).

Tabela 1: Prikaz uspešnosti klasifikatora.

Metrics Classifier	Precision	Accuracy	Recall	F1-Score
LOG	0.93	0.87	0.82	0.87
kNN	0.89	0.83	0.78	0.83
DT	0.85	0.80	0.78	0.82
SVC	0.82	0.83	0.88	0.85
LOG(PCA)	0.95	0.86	0.78	0.86
kNN(PCA)	0.91	0.86	0.82	0.87
DT(PCA)	0.91	0.85	0.80	0.85
SVC(PCA)	0.83	0.84	0.88	0.86
LOG(LDA)	0.95	0.87	0.80	0.87
kNN(LDA)	0.91	0.86	0.82	0.87
DT(LDA)	0.86	0.83	0.82	0.84
SVC(LDA)	0.78	0.82	0.92	0.85

Na Sl. 8. se vidi matrica konfuzije koja je urađena na test skupu za optimalni model LOG. Model je tačno klasifikovao 38 uzoraka klase 0 tj. pravih negativnih i 42 uzorka klase 1 tj. pravih pozitivnih, dok je napravio 3 lažno pozitivna i 9 lažno negativnih predikcija.

True label	0	38	3
	1	9	42
		0	1
		Predicted label	

Sl. 8. Matrica konfuzije optimalnog modela.

VI. REFERENCE

[1] "Heart Disease." MedlinePlus, U.S. National Library of Medicine, <<https://medlineplus.gov/heartdiseases.html>> (2022).

[2] "Heart Disease Facts." Centers for Disease Control and Prevention, <https://www.cdc.gov/heart-disease/data-research/facts-stats/?CDC_AAref_Val=https://www.cdc.gov/heartdisease/facts.htm> (2022).

[3] Heart Failure Prediction Dataset, <<https://www.kaggle.com/fedesoriano/heart-failure-predict>

ion> (2021).

[4] Praktikum iz mašinskog učenja, Tijana Nosek, Branko Brkljač, Danica Despotović, Milan Sečujski, Tatjana Lončar-Turukalo; Univerzitet u Novom Sadu, 2020.

[5] Prepoznavanje oblika za inženjere, Vladimir Crnojević; Univerzitet u Novom Sadu, 2014.